

基于多路段自然驾驶轨迹数据的变道风险 机器学习预测与跨路段泛化性研究

作者姓名^{1*}, 作者姓名²

摘要

针对变道风险预测模型在路段间可迁移性不明确这一关键问题,本研究基于CQSkyEyeX自然驾驶轨迹数据集,系统评估了四种机器学习模型在5个高速公路场景(路基段、桥梁段、分合流区)中的跨路段泛化性能。首先,通过整合mTTC、THW、PET和ETTC等多维度替代安全指标,构建了速度自适应的加权评分体系,实现变道风险的三级标注(高风险323辆、中风险608辆、低风险643辆,共计1,574个变道样本)。随后,对XGBoost、Random Forest、MLP和LSTM四种模型分别进行留一路段交叉验证与随机80/20划分对比评估。实验结果表明:树集成模型在跨路段泛化中表现显著优于神经网络模型——XGBoost取得最优跨路段性能(Accuracy=0.761±0.070, Weighted F1=0.759±0.069),领先Random Forest约1.7%,而MLP宏平均F1仅0.520,暴露出严重的少数类分类缺陷。路段几何形态对模型泛化能力具有显著影响:路基段间可迁移性最高(Fold 1 F1=0.821),分合流区最难以泛化(Fold 5 F1=0.631)。SHAP分析一致确认车头时距最小值(Time_Headway_min)为跨路段最稳定的风险判据(XGBoost高风险贡献值+1.251),后方距离与跟车距离的重要性则呈现路段间差异。本研究为首个基于中国高速公路多场景数据的变道风险模型跨路段泛化性系统评估,为实际变道预警系统的模型选择与路段自适应部署提供了实证依据和工程指导。

关键词: 变道风险评估; 机器学习; 跨路段泛化; SHAP可解释性; 替代安全指标; 自然驾驶轨迹

1 引言

交通事故是威胁公共安全的首要因素之一。世界卫生组织数据显示,全球每年约135万人死于道路交通事故,其中与变道操作(Lane Change, LC)相关的碰撞占总事故的4%~10%,并造成约4,120万小时的碰撞延误[12, 25]。与传统跟驰场景相比,变道过程涉及自车与当前车道及目标车道上多辆相邻车辆的复杂交互,其风险评定需同时考量纵向碰撞概率与横向空间暴露[22]。目前,基于历史碰撞数据的宏观安全评估方法因事故样本稀疏、统计周期长而应用受限[9]。为此,研究者广泛引入了以碰撞时间(TTC)[6]、侵入后时间(PET)[9]、停车距离指数(SDI)[15]为代表的替代安全指标(Surrogate Safety Measures, SSMs),通过对实时运动学参数建模实现对潜在冲突的量化表征。

然而，传统 SSMs 在变道风险评估中存在双重局限性。其一，大多数传统指标（如 TTC）仅适用于纵向跟驰场景，假设运动状态保持不变，无法刻画变道过程中的横向交互与动力学时变性 [19, 22]。其二，单维度指标难以完整反映变道事件的多风险源特性——刘振宇与项巧军 [12] 的研究明确指出了传统风险等级分类边界模糊的问题，王涛等 [19] 进一步将上述局限提炼为“行为确定性”与“空间离散性”两个本质缺陷。为克服这些问题，研究者发展了多种综合评估框架：Park 等 [17] 提出变道风险指数（LCRI），通过故障树分析综合碰撞暴露时间与碰撞严重度；Wu 等 [22] 构建了时空风险估计（TSRE）模型，将时间风险水平与空间风险水平统一纳入综合风险指数。这些方法显著改善了变道风险评估的全面性，但其指标组合方式和阈值设定仍以人工经验为主。

近年来，机器学习（ML）方法被逐步引入变道风险预测领域，展现出超越传统规则方法的潜力。冯移冬等 [5] 利用 RF-RFE 特征选择配合 RF、SVM 和 Logistic 回归模型，在高速公路汇入场景中实现了逐道汇入 F1=83% 和连续换道 F1=84% 的分类性能。温惠英等 [21] 使用 XGBoost 结合 SHAP 理论对合流区汇入风险进行判别，XGBoost 以 95.52% 的准确率超过 LightGBM、GBDT 和 RF，并通过 SHAP 分析揭示了速度差、汇入持续时间等关键致险因子。在深度学习方向，DS-LSTM 模型 [2] 通过驾驶风格聚类增强了时序预测能力，CNN-BiLSTM-Attention[28] 则实现了多车型变道风险的综合识别。SHAP（SHapley Additive exPlanations）[13] 和 TreeSHAP[14] 的提出为解决 ML 模型的黑箱可解释性问题提供了博弈论框架。

尽管上述研究展示了 ML 方法在变道风险预测中的可观性能，一个根本性问题仍未得到系统回答：在某一道路场景上训练的变道风险模型，能否有效迁移至几何形态、交通流特性或限速条件不同的其他路段？现有研究的实证分析大多局限于单一数据集或单一道路段落（如仅基于 highD 数据集的 6 个德国高速公路位置 [10] 或基于单一路段的小样本无人机数据）。少数跨数据集研究中，Zhang 等 [27] 报告了 F1 值 18%~25% 的跨数据集退化，Wang 等 [20] 确认了风险因子在不同站点间的异质性分布。该问题的答案直接决定了变道预警系统实际部署时是否需要为每一个路段重新训练专用模型，具有显著的工程与经济含义。

针对上述研究空白，本文基于 CQSkyEyeX 数据集 [23] 中 5 种不同道路几何形态的实际场景，开展变道风险 ML 预测模型的跨路段泛化性系统研究。主要贡献如下：

1. 多路段评估基准构建：基于涵盖路基段、整体式桥梁段和分合流区三种道路类型的 1,574 个变道样本，建立了多指标加权安全评分 → 三级风险标签的完整标注管线，为跨路段泛化评估提供了统一的数据基础。
2. 四模型跨路段泛化对比：通过留一路段交叉验证（5-fold cross-location CV）与随机划分的对照设计，量化了 XGBoost、Random Forest、MLP 和 LSTM 四种代表性模型的跨路段性能退化程度，揭示了树集成模型与神经网络模型在泛化行为上的本质差异。
3. SHAP 驱动的风险因子普适性分析：利用 XGBoost 和 Random Forest 的 SHAP 值多模型一致性分析，首次在跨路段维度上分离了变道风险的普适性特征（通用因子）与路段特异性特征（场景因子），为路段自适应模型设计提供了特征层面的依据。

本文其余部分组织如下：第 2 节系统综述 SSMs、变道风险 ML 方法和跨路段泛化研究；第 3 节详述数据集、风险标注、特征工程、模型构型和评估策略；第 4 节报告数据概览、跨路段性能对比、随机划分基线以及 SHAP 可解释性分析的结果；第 5 节围绕泛化机制、特征普适性、实践应用和局限性展开讨论；第 6 节总结全文并展望未来方向。

2 相关研究

2.1 替代安全指标与变道风险评估

替代安全指标（Surrogate Safety Measures, SSMs）构成了交通冲突技术的理论基础。自 Hayward[6] 于 1971 年首次提出 TTC 概念以来，SSMs 已发展出涵盖时间型（TTC、PET）、距离型（SDI）和减速度型（DRAC）的完整指标体系[18]。TTC 因公式简洁、物理含义明确而最为普及，但其基本假设——后车速度大于前车且运动状态不变——在变道场景的动态多车交互中频繁失效[12]。Ozbay 等[16] 通过引入加速度信息提出了修正 TTC（MTTC），Ward 等进一步将 MTTC 拓展至二维空间，Minderhoud 与 Bovy[15] 则发展出暴露时间 TTC（TET）和累积 TTC（TIT）两种扩展指标，通过统计低于阈值的累计时长来刻画碰撞风险的时间暴露度。

进入变道风险的综合性评估阶段，Park 等[17] 的开创性工作将故障树分析（FTA）引入变道领域，通过“碰撞暴露时间 $\times$ 碰撞严重度”的逻辑构建了变道风险指数（LCRI），为变道安全的多维度量奠定了基础。Wu 等[22] 在该框架上进一步发展了时空风险估计模型（TSRE），明确区分了变道前（时间风险评估）和变道中（空间风险评估）两个阶段的差异化风险计算模式。Xue 等[25] 则从车辆制动性能差异切入，引入安全裕度（Safety Margin）概念，系统考察了制动能力约束和驾驶者反应时间对变道风险的影响。

在更为前沿的方向，风险场理论作为一类范式革新被引入交通冲突研究。刘振宇与项巧军[12] 将驾驶风险场类比于静电场，构建了由驱动力场和风险排斥场复合而成的二维风险表征（F-F Diagram），通过高斯混合模型（GMM）聚类实现了风险等级的自适应划分。王涛等[19] 则以高斯混合分布建模车辆未来轨迹的概率分布，通过变分推断方法推导了冲突风险的闭式解，实现了从“点式确定性评估”到“场式概率性评估”的范式转变。

2.2 机器学习驱动的变道风险预测

ML 方法因其对非线性高维关系的强大建模能力，在变道风险分类预测中表现出优于传统统计模型的性能。在特征维度，冯移冬等[5] 使用皮尔逊相关系数初步筛选再配合 RF-RFE 递归特征消除的二级策略，从 17 个候选特征中确定了 13 个最优判别特征；温惠英等[21] 则从微观运行状态与宏观交通状态两个视角系统构建了 32 维特征空间，并通过 Z-score 标准化与皮尔逊相关性检验消除了多重共线性。在模型维度，树集成方法——特别是 XGBoost 和 Random Forest——因对表格化结构化数据的天然适应性而被广泛采用[3, 4]。XGBoost 通过引入二阶泰勒展开的梯度近似和正则化项，有效抑制了对训练数据的过度记忆[4]；RF 则依赖于 Bootstrap 随机抽样和特征子集选择带来的多

样性增益 [3]。

深度学习方法提供了时序特征自动提取的替代路径。DS-LSTM 模型 [2] 将驾驶风格聚类结果作为附加特征融入 LSTM 网络，在高速变道数据集上显著提升了预测精度；CNN-BiLSTM-Attention 架构 [28] 通过多尺度卷积特征提取与双向时序注意力机制，实现了对三种车型和两种变道方向风险的综合建模。

在可解释性方向，SHAP[13] 提供了源自 Shapley 值的统一特征归因框架，Tree-SHAP[14] 进一步以多项式时间复杂度实现了对树模型的高效解释。多项变道安全研究 [11, 21] 已将 SHAP 应用于关键特征识别，但其分析维度多停留于“哪个特征重要”，而未触及“同一特征在不同路段上是否同等重要”这一跨场景维度——这正是本研究的切入点之一。

2.3 跨路段与跨数据集泛化研究

模型泛化性（Model Generalization）研究在交通领域尚处于早期阶段。Huang 等 [8] 发现，变道风险模型在桥隧段训练后直接部署至合流段时，预测可靠度显著下降。Zhang 等 [27] 通过对 highD 与 NGSIM 两个公开数据集的交叉验证，定量揭示了跨数据集 F1 下降 18%~25% 的迁移脆弱性，并指出道路几何特征和限速差异是性能退化的主要归因变量。Wang 等 [20] 的多站点驾驶风险分析进一步支持了这一发现：车头时距等部分因子呈现跨站点稳定性，而速度方差和加速度冲击度则呈现明显的站点间异质性。

在迁移学习方法中，Ahmed 等 [1] 探索了基于域自适应的变道预测模型迁移策略，但其性能提升（3%~5%）尚未达到可忽略原始训练效果的实用水平。Zhang 等 [26] 在跟驰与变道模型的行为参数迁移研究中指出，模型在源域上习得的参数分布难以直接映射到目标域，暗示了根本上需要场景感知型模型架构。

总体而言，现有跨场景泛化研究存在三个局限：（1）多使用仿真的理想化变道场景，缺乏对实际复杂道路几何形态的覆盖；（2）训练集与测试集差异主要通过数据分布漂移来刻画，缺少对模型类型——特别是树模型与神经网络——泛化行为差异的比较分析；（3）尚未结合 SHAP 等可解释性工具，从特征重要性动态变化的角度解释泛化性能退化的内因。本研究围绕上述三个局限展开设计。

3 方法

3.1 CQSkyEyeX 数据集

本研究采用 CQSkyEyeX 自然驾驶轨迹数据集 [23]，由重庆交通大学徐进教授团队构建并公开¹。该数据集使用搭载 DJI Mavic 3 无人机在中国重庆市多条高速公路上空拍摄，采用改进的 YOLOX 目标检测模型配合 DeepSORT 多目标跟踪算法提取车辆轨迹 [24]。数据集包含视频稳像（SURF/FLANN）、高效通道注意力机制（ECA）、浅层特征融合模块等系列优化，在定位精度（均方根误差 < 0.10 m）、速度精度（< 1.5 km/h）和

¹数据集官网：<http://www.cqskyeyex.com/CQSkyEyeX>

跟踪完整性（MOTA 97.2%, MOTP 96.8%）三个维度上均达到先进水平。原始轨迹采样率为 30 Hz，研究中对数据进行统一降采样至 5 Hz 以减少模型计算复杂度。

本研究选取数据集中已被完整标注和公开的前 5 个场景，其道路几何形态涵盖三种典型高速公路段落类型：路基段、整体式桥梁段和分/合流区。表 1 汇总各场景的详细特征。

表 1: CQSkyEyeX 数据集 5 场景特征描述

场景	道路名称	路段类型	单向车道数	限速 (km/h)	拍摄长度 (m)	变道样本数
Loc1	重庆绕城高速	路基基本段	3	120	~420	151
Loc2	重庆绕城高速	路基基本段	3	120	~420	243
Loc3	渝蓉高速	整体式桥梁段	3	120	~420	440
Loc4	渝蓉高速	整体式桥梁段	3	120	~420	306
Loc5	兰海高速（重庆内环）	分/合流区	3	100	~350	434

全部 5 个场景的车辆轨迹参数输出共包含车辆坐标 (X, Y)、速度 (Velocity)、纵向/横向速度分量、纵向/横向加速度分量、行驶方向、车道 ID、与左右车道线距离，以及自车前后左右多方向的邻车 ID 与间距 (B_Dist, LB_Dist, RB_Dist, LF_Dist, RF_Dist, Following_dist)、车头时距 (Time Headway) 和碰撞时间 (TTC) 等信息。变道样本的提取标准为：以车辆跨越车道线时刻 (t_0) 为参考点，截取 t_{-90} 至 t_{-15} 的帧区间，共计 75 帧。原始数据的轨迹提取帧率为 25 Hz，75 帧对应恰为 3 s 的时间窗口。选择 3 s 窗口的理据是：高速公路自由变道 (discretionary lane change) 的完整周期——从产生变道意图、通过后视镜和侧视镜观察周围交通状况、评估可接受间隙、执行横向偏移至车身姿态稳定——通常持续 3~5 s[22, 25]，截取自变道执行前 3.6 s 至前 0.6 s ($t_{-90} \sim t_{-15}$, 25 Hz) 的 75 帧数据恰好覆盖了意图产生至操作初期的完整认知-决策-执行链路，同时避免了窗口过长引入与当前变道事件无关的历史巡航状态，以及窗口过短遗漏关键预判信息。经移动平滑去噪和异常帧过滤后，最终获得 1,574 个有效变道样本。

经预处理和窗口截取后，单个变道样本的轨迹俯视图及各 SSM 指标的时序剖面如图 1 和图 2 所示。图 1 展示了 CQSkyEyeX 数据集中某个典型场景经坐标变换和车道线拟合后的车辆轨迹全局俯视图，各车道中心线以拟合多项式曲线标定，彩色轨迹线对应不同车辆的行驶路径，可见变道车辆（自车）跨越车道线的完整空间轨迹。图 2 以六面板布局展示了一辆变道车辆在其 75 帧采样窗口内的多维运动学参数演化过程：左上方为 Frenet 坐标下的轨迹位置及与车道线的相对关系；左中为合速度与纵向/横向速度分量的时变曲线；右上方为 TTC 与车头时距 (THW) 的时间序列；右中为与前后左右邻车的纵向间距变化；左下方为纵向/横向加速度时变；右下方为与各邻车的扩展碰撞时间 (ETTC)。该可视化证实了变道窗口内各风险指标的时序非平稳性——例如 TTC 在横向偏移启动时刻 ($\sim t_{-20}$) 出现显著下探，邻车间距在跨越车道线前后发生剧烈重组——这支持了后续以统计聚合特征（均值 / 标准差 / 最小值 / 最大值）捕获时序分布中的极端状态信息，而非仅依赖单帧瞬时值的特征工程策略。




图 1: 典型路段车辆轨迹俯视图（经坐标变换与车道线拟合）。彩色曲线为不同车辆行驶轨迹，黑色虚线为拟合车道中心线。




图 2: 单车变道车辆 75 帧采样窗口内的多维运动学参数面板图。从左至右、从上至下依次为：Frenet 轨迹与车道线关系、速度（合速度/纵向/横向）、TTC 与 THW、各方向邻车车距、纵向与横向加速度、各方向扩展碰撞时间（ETTC）。

3.2 指数化连续风险评分体系

为实现对变道轨迹的无监督风险标注，同时克服传统离散阈值打分法中类别边界僵硬、对指标小幅度变化不敏感的缺陷，本文采用基于指数衰减函数的连续风险评分方案。该方法的核心设计原则为：替代安全指标值越小（越危险），评分贡献越接近于该指标的预设权重；指标值越大（越安全），贡献以负指数函数衰减趋于零。下式给出了五个核心 SSM 的具体数学定义。

3.2.1 变道场景的车辆交互关系

在变道执行过程中，自车（Subject Vehicle, SV）与周边四辆邻车构成典型的五车交互系统（图 3）：当前车道正前方车辆（Preceding Vehicle, PV）、当前车道正后方车辆（Following Vehicle, FV）、目标车道正前方车辆（Lead Vehicle, LV）、目标车道正后方车辆（Lag Vehicle, LgV）。不同的 SSM 指标度量的正是 SV 与特定邻车之间的冲突紧迫度，明确这一映射关系是后续风险评分公式的物理前提。




图 3: 变道车辆（SV）与周边四辆邻车的交互关系。LV：目标车道前车（Lead Vehicle）；LgV：目标车道后车（Lag Vehicle）；PV：当前车道前车（Preceding Vehicle）；FV：当前车道后车（Following Vehicle）。箭头示意车辆行驶方向与横向偏移意图。

本节所定义五个替代安全指标与上述车辆对的对应关系如下：mTTC 和 THW 度量 SV 与 PV 之间的纵向碰撞风险（当前车道追尾）；PET 度量 SV 与目标车道邻车（LV 或 LgV）先后通过同一空间点的时间逼近程度；F_ETTC 将碰撞时间拓展至二维平面，度量 SV 与 LV 沿碰撞危险方向的综合逼近速率；OL_PET 度量 SV 横向侵入目标车道时与 LgV 的侧向时间裕度。跟驰风险评分（式 8）中的 B_mTTC 则度量 FV 与 SV 之间的后向追尾风险。

3.2.2 替代安全指标的数学定义

(1) 修正碰撞时间（mTTC）。传统 TTC 假设运动状态恒定而忽略加速度，mTTC[16] 将加速度纳入碰撞时间估计。设两车相对位置矢量为 $\Delta \mathbf{s} = (\Delta x, \Delta y)$ ，相对速度矢量为 $\Delta \mathbf{v} = (\Delta v_x, \Delta v_y)$ ，相对加速度矢量为 $\Delta \mathbf{a} = (a_x, a_y)$ ，则：

$$\text{mTTC} = \frac{-\langle \Delta \mathbf{v}, \Delta \mathbf{s} \rangle + \sqrt{\langle \Delta \mathbf{v}, \Delta \mathbf{s} \rangle^2 + 2\langle \Delta \mathbf{a}, \Delta \mathbf{s} \rangle \|\Delta \mathbf{s}\|^2}}{2\langle \Delta \mathbf{a}, \Delta \mathbf{s} \rangle} \quad (1)$$

其中 $\langle \cdot, \cdot \rangle$ 表示向量的内积。当后车速度不大于前车（分母为 0 或根号内为负）时， $\text{mTTC} \rightarrow \infty$ ，表示当前运动状态下不可能发生碰撞。

(2) 车头时距（THW）。表征自车以当前速度到达前车当前位置所需的时间：

$$\text{THW} = \frac{d_f}{v_e} \quad (2)$$

其中 d_f 为自车前端至前车尾端的纵向间距 (m), v_e 为自车速度 (m/s)。THW 直接反映了驾驶人可用的反应时间储备。

(3) 侵入后时间 (PET)。度量两车轨迹在空间中先后通过同一冲突点的时间差 [9]:

$$\text{PET} = t_2 - t_1 \quad (3)$$

其中 t_1 为第一辆车离开冲突区域的时刻, t_2 为第二辆车到达冲突区域的时刻。PET 越小表示冲突越紧迫。

(4) 前向扩展碰撞时间 (F_ETTC)。将碰撞时间从纵向一维拓展至二维平面 [22]。设自车位置为 $\mathbf{s}_e$, 前车位置为 $\mathbf{s}_f$, 二者相对速度矢量为 $\mathbf{v}_{ef} = \mathbf{v}_e - \mathbf{v}_f$, 夹角 $\theta = \angle(\mathbf{v}_{ef}, \mathbf{s}_f - \mathbf{s}_e)$, 则:

$$\text{F_ETTC} = \frac{\|\mathbf{s}_f - \mathbf{s}_e\|}{\|\mathbf{v}_{ef}\|} \cdot \cos \theta \quad (4)$$

$\cos \theta$ 项剔除横向速度分量中不与自车-前车连线方向重合的部分, 使得 F_ETTC 等价于沿碰撞危险方向投影后的碰撞时间。

(5) 超越车道侵入后时间 (OL_PET)。针对相邻车道变道场景, 度量自车横向运动侵入邻车道的紧迫度:

$$\text{OL_PET} = \frac{d_{\text{lat}}}{v_{\text{lat}}} \quad (5)$$

其中 d_{lat} 为自车侧缘至相邻车道边界线的横向距离 (m), v_{lat} 为自车横向速度分量 (m/s)。

3.2.3 变道风险评分函数

设单个变道样本的 75 帧时序中, 指标 i 在时刻 t 的观测值为 $v_i(t)$ 。将指标值映射为 $[0, w_i]$ 区间内的风险贡献:

$$S_{\text{LC}}(t) = K \cdot \sum_{i \in \mathcal{M}} w_i \cdot \exp\left(-\frac{v_i(t)}{k_i}\right) \quad (6)$$

$$S_{\text{LC}} = K \cdot \sum_{i \in \mathcal{M}} w_i \cdot \max_{t \in [1, 75]} \exp\left(-\frac{v_i(t)}{k_i}\right) \quad (7)$$

式 (6) 为逐帧风险分, 式 (7) 为单辆车最终风险分 (取各指标全窗口最危险帧的最大贡献再求和)。 $\mathcal{M} = \{\text{mTTC}, \text{THW}, \text{PET}, \text{F_ETTC}, \text{OL_PET}\}$, 权重 $\{w_i\} = \{0.25, 0.20, 0.20, 0.20, 0.15\}$, K 为下节定义的速度修正因子。

3.2.4 衰减常数 k_i 的标定

衰减常数 k_i 控制 $\exp(-v/k)$ 对指标数值变化的敏感度： k 越小，在相同指标值下衰减越陡峭，区分度越细。 k_i 的取值基于各指标的典型值域和危险阈值区间：

- **mTTC, PET, F_ETTC, OL_PET:** $k = 12.0 \text{ s}$ 。这四类碰撞时间型指标的典型观测值分布在 $0 \sim 20 \text{ s}$ 区间，学术界广泛采用的 TTC 危险阈值为 $2.0 \sim 5.0 \text{ s}$ [15, 16]。取 $k = 12.0$ 时： $\exp(-2/12) \approx 0.85$ （非常危险，贡献接近 $0.85w_i$ ）， $\exp(-5/12) \approx 0.66$ （中度危险）， $\exp(-15/12) \approx 0.29$ （安全）。 $k \approx 2.4 \times \sim 6 \times$ 危险阈值的比例关系使得贡献值在 $0.3 \sim 0.9$ 的宽度区间内平缓变化，避免边界跳变。
- **THW:** $k = 6.0 \text{ s}$ 。THW 的典型观测区间（ $0 \sim 8 \text{ s}$ ）较碰撞时间类指标更窄，且驾驶行为研究表明 $\text{THW} < 1.0 \text{ s}$ 时追尾风险急剧上升 [18]。取 $k = 6.0$ 时： $\exp(-0.5/6) \approx 0.92$ （极度危险）， $\exp(-1/6) \approx 0.85$ （高度危险）， $\exp(-3/6) \approx 0.61$ （中度危险）， $\exp(-8/6) \approx 0.26$ （安全）。较小的 k 使得 THW 在 $0 \sim 3 \text{ s}$ 的关键判别区间内具有更细粒度的区分能力。

3.2.5 跟驰车辆风险评分

对于与目标变道车辆发生交互的跟驰车辆（前车或后车），风险评分采用缩减的指标集和不同的权重分配，以反映跟驰场景仅关注前后向碰撞风险的特性：

$$S_{\text{FW}} = K \cdot \sum_{i \in \mathcal{M}_{\text{FW}}} w_i \cdot \max_{t \in [1, 75]} \exp\left(-\frac{v_i(t)}{k_i}\right) \quad (8)$$

其中 $\mathcal{M}_{\text{FW}} = \{\text{mTTC}, \text{THW}, \text{B_mTTC}\}$ ，对应权重 $\{w_i\} = \{0.40, 0.30, 0.30\}$ ，B_mTTC 为后向修正碰撞时间（与后车之间的 mTTC），其衰减常数同为 $k = 12.0 \text{ s}$ 。跟驰评分的权重向 mTTC 倾斜，因为跟驰场景下追尾碰撞是最主要的事故形态。跟驰评分与变道评分共享同一速度修正因子 K ，两者可直接对比。

3.2.6 速度修正因子 K 与参数 $B = 1.3$

不同道路限速会系统性改变车辆的运行速度基线，相同的 SSM 数值在不同限速下对应的风险水平并不等价。例如 $\text{THW} = 2 \text{ s}$ 在 120 km/h 限速道路上（ $v_e \approx 33.3 \text{ m/s}$ ，间距约 67 m ）与 100 km/h 道路上（ $v_e \approx 27.8 \text{ m/s}$ ，间距约 56 m ）的物理安全裕度不同。为此引入速度自适应的非线性修正因子：

$$K = \begin{cases} 1, & v_{85} \leq v_0 \\ \left(\frac{v_{85}}{v_0}\right)^B, & v_{85} > v_0 \end{cases} \quad (9)$$

其中 v_{85} 为单辆车 75 帧速度序列的第 85 百分位数（m/s）， v_0 为该路段的道路限速（m/s），幂指数 $B = 1.3$ 。

$B = 1.3$ 的取值依据。车辆碰撞动能 $E = \frac{1}{2}mv^2$ 表明单次碰撞的潜在严重度与速度的平方成正比。若风险修正严格遵循动能关系，应取 $B = 2$ ($K \propto (v/v_0)^2$)。然而，SSM 指标中的时间型度量（mTTC、PET、THW 等）已经在自身的计算过程中内嵌了速度信息——相同间距下速度越高则 TTC 越小、评分贡献越大，再施加纯动能平方修正将导致高速行驶场景的风险评分被双重放大。反之，若完全不进行速度修正（ $B = 0$ ），则低速限场景（如 Loc5）中的激进驾驶行为与高速限场景（如 Loc1~4）中的正常驾驶行为可能获得相近的风险评分，失去区分力。取 $B = 1.3$ 作为折中值，其物理含义是：风险与 $v^{1.3}$ 成正比，介于线性增长（ $B = 1$ ，仅由 SSM 自身承载速度信息）和动能平方增长（ $B = 2$ ，速度的全部动能效应均由修正项承担）之间，兼顾了时距类指标内含的速度维度和车速动能的外生风险贡献。幂指数形式 $(v_{85}/v_0)^B$ 确保了当车辆以接近限速的速度行驶时修正幅度微小（ $K \approx 1$ ），只有当显著超速时才有实质性惩罚。

3.2.7 三级风险标签映射

将连续评分 S_{LC} （或 S_{FW} ）通过固定阈值映射为可用于监督学习的三级离散标签：

表 2: 不同场景的风险等级阈值

场景	中风险阈值	高风险阈值
变道车辆 (S_{LC})	0.40	0.60
跟驰车辆 (S_{FW})	0.20	0.35

跟驰场景的阈值低于变道场景的原因在于：跟驰指标集仅包含 3 项且均为直接碰撞相关指标，评分基数系统性低于 5 项指标构成的变道评分。不同场景采用独立阈值可视为对不同事故先验概率的标定，在等效风险水平下产出可比的标签分布。

3.3 聚合特征工程

对每辆车 75 帧的时序轨迹，采用统计聚合策略将变长时间序列映射为固定维度特征向量。针对 13 个基础运动学指标（表 3），各计算四类聚合统计量：均值（mean）、标准差（std）、最小值（min）和最大值（max），共计生成 $13 \times 4 = 52$ 维特征。均值反映总体行为倾向，标准差刻画驾驶控制的稳定性，最值捕捉极端危险时刻的信息。对 inf 与缺失值统一以 0 填充处理。

表 3: 基础运动学特征列表

类别	特征	物理含义
速度类	Velocity, long_Vel, lat_Vel	合速度、纵向/横向分量
加速度类	long_Acc, lat_Acc	纵向/横向加速度
距离类	Following_dist, B_Dist, LB_Dist, RB_Dist, LF_Dist, RF_Dist	与各方向邻车的距离
时间类	TTC, Time_Headway	碰撞时间与车头时距

3.4 评估机器学习模型

本研究选取四类代表性模型，覆盖树集成方法与神经网络方法两个主要范式，以确保跨路段泛化行为差异的充分揭示。

XGBoost (Extreme Gradient Boosting)。基于梯度提升决策树框架 [4]，通过自适应学习率和二阶泰勒展开实现高效优化。配置：500 棵基学习器，最大树深 5，学习率 0.05，列采样率 0.8，早停轮次 20。使用多类 softmax 目标函数。

Random Forest (RF)。基于 Bagging 策略的集成树模型 [3]，通过 Bootstrap 重采样与随机特征子集实现去相关性。配置：300 棵决策树，最大树深 10，最小叶节点样本数 4，类别权重平衡 (class_weight = 'balanced')。

MLP (Multilayer Perceptron)。两层隐藏层前馈神经网络 (64 → 32 神经元)，ReLU 激活函数，自适应学习率策略，基于验证集的早停正则化，数据经 StandardScaler 标准化。

LSTM (Long Short-Term Memory)。两层循环神经网络 [7] (64 → 32 神经元单元)，配合 25% Dropout 防止过拟合，Adam 优化器 (初始学习率 5×10^{-4})，早停耐心值 15。LSTM 是四个模型中唯一直接接受原始 75 帧时序输入 (而非聚合特征) 的模型，以检验端到端时序学习在跨路段泛化中的表现。

3.5 评估策略

本研究设计了两种互补的评估协议以区分模型的内在拟合能力与跨场景泛化能力：

1. 留一路段交叉验证 (**Cross-Location CV**)。依次将 1 个路段的全部样本设为测试集，其余 4 个路段的样本合并作为训练集，重复 5 次使得每个路段恰好充当一次测试集。该协议直接模拟变道预警系统实际部署中最常见的场景：在新路段上线时，仅有旧路段的历史标注数据可用于模型训练。评估指标对各 fold 的 Accuracy、Weighted F1 和 Macro F1 分别报告均值 ± 标准差。
2. 随机 80/20 划分 (**Random Split**)。将所有 1,574 个样本按 80%:20% 比例进行分层随机划分 (stratified by risk class)，训练集 1,259 辆，测试集 315 辆。该协议消除路段间的数据分布漂移，代表模型在同一数据分布内部所能达到的性能上限，作为跨路段泛化性能的对照基线。两种评估间性能的差距直接量化了由路段特异性特征分布差异导致的模型退化程度。

在可解释性维度，对树模型 (XGBoost 和 RF) 分别在全部 1,574 样本上计算 SHAP 值，生成 beeswarm 散点汇总图和特征重要性柱状图。通过对比两个模型对同一特征的归因一致性，识别跨模型稳健的风险因子；结合对各个 Cross-Location fold 结果的差异分析，进一步判断因子重要性的路段间稳定性。

4 实验结果

4.1 数据概况与风险分布

1,574 个变道样本的三级风险标签分布为：高风险 323 辆（20.5%）、中风险 608 辆（38.6%）、低风险 643 辆（40.9%），呈现轻度类别不均。各场景间的风险构成存在显著差异（图 4）：Loc5（分合流区）高、中风险车辆占比较高，这与合流区匝道车辆须在有限空间内强制换道并应对主线车流的特征一致；Loc1（路基段）和 Loc3（桥梁段）则低风险比例较高，反映了自由流条件下变道操作具有更充裕的安全裕度。




图 4: 各场景高中低风险车辆数量分布对比

高风险变道点的空间分布热力图（图 5）揭示了一个值得注意的现象：高风险帧并非在车道面上均匀散布，而是在特定空间位置——如合流区末端邻近鼻端处、车道交叉点附近、以及桥梁段纵坡变化区间——呈现显著的聚集现象。该发现与 Wu 等 [22] 关于“变道风险具有强空间非均匀性”的观点一致，为路段特异性风险评估策略的必要性提供了直观的图形证据。




图 5: 5 个场景高风险变道点空间分布热力图（车道线以白/深灰色勾勒）

4.1.1 变道车辆与跟驰车辆的风险水平对比

为验证变道操作是否在本质上比跟驰驾驶具有更高的瞬时碰撞风险，本研究利用指数化连续风险评分体系，对所有 5 个路段中变道车辆和同时段同路段跟驰车辆的风险分

进行了头对头比较（图 6），样本量分别为 1,521 辆（变道）和 6,457 辆（跟驰）。




图 6: 变道车辆与跟驰车辆连续风险分分布对比。（左上）排除零分样本的分布直方图，内嵌小窗为 score=0 占比；（右上）累积分布函数（CDF），垂直虚线分别标注变道（红色）和跟驰（蓝色）的中/高风险阈值；（左下）箱线图含均值菱形标记，右上角附关键统计量；（右下）按各自场景阈值的三级风险等级比例堆叠图。

从分布直方图（左上）可见，跟驰车辆中风险分恰好为零的样本比例（内嵌柱形，12.4%）约为变道车辆（1.3%）的十倍，表明大量跟驰场景在实际运行中处于完全无冲突的安全状态，而变道车辆因涉及横向跨越和与多辆邻车的交互，几乎不存在零风险情况。在排除零分样本后，变道车辆的非零风险分密度峰值区间（0.3~0.5）显著高于跟驰的 0.1~0.2——即便剔除无冲突样本，变道的条件风险分布仍然整体右移。

累积分布函数（右上）提供了系统性的定量证据：在任意给定风险分水平上，跟驰 CDF 始终位于变道上方，即跟驰样本中有更高比例落在较低分数区间。以变道中风险阈值 0.40 为参照，对应跟驰 CDF 值约 0.85，表明仅约 15% 的跟驰样本达到变道场景“中风险及以上”的分数水平，这正是对不同场景施加差异化风险等级阈值（表 2）的统计学依据。

箱线图（左下）揭示了分布形态的差异：变道风险分中位数（0.465）和上四分位数均系统性高于跟驰（0.236），且变道分数的须线延伸至更大的极值区域。等级比例堆叠图（右下）给出最具实践含义的对比：在各自场景的阈值下，变道车辆高风险占比 25.0%（380/1,521），跟驰车辆仅为 11.0%（712/6,457），前者约为后者的 2.3 倍。综合四个维度的多角度对比，可得出稳健结论：在相同交通环境与指数化评分体系下，变道操作相较

于跟驰驾驶具有系统性的更大瞬时碰撞风险，这一差异在跨 5 个路段中一致成立，且不受阈值选取的具体数值影响。

4.2 跨路段模型泛化性能

表 4 报告了四种模型在留一路段交叉验证中的综合性能。核心发现如下：

表 4: 留一路段交叉验证性能汇总（均值 $\pm$ 标准差）

模型	Accuracy	Weighted F1	Macro F1
XGBoost	0.761$\pm$0.070	0.759$\pm$0.069	0.733$\pm$0.066
Random Forest	0.745 $\pm$ 0.069	0.742 $\pm$ 0.067	0.729 $\pm$ 0.070
LSTM	0.612 $\pm$ 0.062	0.598 $\pm$ 0.063	0.572 $\pm$ 0.047
MLP	0.591 $\pm$ 0.083	0.586 $\pm$ 0.086	0.520 $\pm$ 0.075

模型类型对泛化的影响。XGBoost 在所有三个指标上均取得最优值，跨路段 Weighted F1 达 0.759。Random Forest 紧随其后（F1=0.742）。两类树集成模型的性能显著优于神经网络模型：LSTM 跨路段 F1 仅为 0.598，比 XGBoost 低约 16 个百分点；MLP 最低（0.586），其 Macro F1 更跌至 0.520，暴露出中、高风险类的严重误分类。这一差距的根本原因在于：（1）树模型天然对特征尺度和样本分布偏移具有鲁棒性；（2）神经网络——特别是 MLP——在处理 52 维高度相关的聚合特征时，会过度拟合训练路段中特征间的特定协方差结构，当测试路段数据不再遵循该结构时泛化性能便急剧退化；（3）LSTM 虽然具有时序建模优势，但 1,574 个样本量对于深度循环网络的训练而言可能不足，加之不同路段变道持续时间的固有差异使得固定 75 帧窗口未必是最优选择。

路段特异性分析。各 fold 的逐路段结果（表 5 和图 7）进一步揭示了路段几何形态对模型绩效的显著影响。

Loc1（Fold 1, 路基段）是泛化最优的场景（XGBoost F1=0.821）。Loc1 和 Loc2 同属重庆绕城高速路基段，训练集包含了 Loc2 的充分样本，测试集模式与训练集高度一致。Loc5（Fold 5, 分合流区）在所有 fold 中表现最差（XGBoost F1=0.631），其原因可从三个层面解析：（i）分合流区涉及主线与匝道的强制交互，交通流动态模式与直线基本路段存在本质差异；（ii）限速 100 km/h 低于其余 4 个场景的 120 km/h，速度修正系数的系统性差异改变了特征空间分布；（iii）训练集中无任何分合流区样本，模型从未接触过该场景特有的加速车道强制汇入行为。

表 5: Cross-Location CV 各 Fold XGBoost 性能明细

Fold	测试场景	测试样本	Accuracy	Weighted F1	Macro F1
Fold 1	Loc1（路基段）	151	0.821	0.817	0.814
Fold 2	Loc2（路基段）	243	0.807	0.808	0.758
Fold 3	Loc3（桥梁段）	440	0.743	0.743	0.708
Fold 4	Loc4（桥梁段）	306	0.801	0.796	0.763
Fold 5	Loc5（分合流区）	434	0.631	0.631	0.620




图 7: 跨 Location 模型性能对比（左：Cross-Location F1；中：Macro F1；右：混淆矩阵）

4.3 随机划分基线对比

表 6 呈现了随机 80/20 划分——即“同分布内”评估——的结果。将其与表 4 对比，可精确量化由路段间分布漂移带来的性能退化。

表 6: 随机 80/20 分层划分评估结果

模型	Accuracy	Weighted F1	Macro F1
XGBoost	0.775	0.773	0.763
Random Forest	0.740	0.737	0.726
MLP	0.644	0.635	0.612
LSTM	0.629	0.612	0.594

对比两类评估策略的 F1 差异具有显著的分析价值：

- **XGBoost:** 随机划分 F1 = 0.773，跨路段 F1 = 0.759，降幅仅 1.4%（1.4 个百分点）。该微小差距表明 XGBoost 学到的特征-风险映射关系具有跨路段的可迁移性。
- **RF:** 跨路段 F1 较随机划分反而提升了 0.5%（0.742 vs 0.737）。这一反直觉现象可归因于：在随机划分中部分 Loc5 的低质量样本被划分至测试集增加了评估噪声，而 Cross-Location CV 中训练集规模更大（前 4 个 fold 平均 1,289 样本 vs 随机划分的 1,259），更丰富的训练数据可能抵消了路段差异。
- **MLP:** 跨路段 F1 较随机划分下降 4.9%（0.586 vs 0.635），降幅约为 XGBoost 的 3.5 倍。MLP 对训练分布的记忆效应——即过度编码路段特有的“特征-标签条件概率”——在跨路段场景中暴露无遗。

- **LSTM**: 降幅为 1.4% (0.598 vs 0.612), 与 XGBoost 相近, 但其绝对值 (0.598) 仍然远低于可实用的水平。




图 8: 四模型在随机划分条件下的混淆矩阵对比

需要注意的是，图 7 中的柱状图还包含了各 fold 的方差信息（误差棒），反映了跨路段性能的不确定性：Loc3 和 Loc5 的 fold 间波动明显高于 Loc1 和 Loc2，进一步佐证了道路类型是影响预测稳定性的关键因素。

4.4 SHAP 可解释性分析

4.4.1 全局特征重要性

表 7 汇总了 XGBoost 模型下单特征对三类风险的 SHAP 贡献值。

表 7: XGBoost SHAP Top-5 特征贡献值（按总体影响力排序）

排名	特征	高风险贡献	中风险贡献	低风险贡献
1	Time_Headway_min	+1.251	+0.309	+0.481
2	B_Dist_mean	+0.160	+0.096	+0.347
3	Time_Headway_max	+0.037	+0.048	+0.369
4	B_Dist_max	+0.135	+0.051	+0.262
5	Following_dist_min	+0.155	+0.069	+0.138

Random Forest 的 SHAP 排序 (Top-5: Time_Headway_min, Time_Headway_mean, Following_dist_min, Following_dist_max, Time_Headway_max) 与 XGBoost 高度一致，表明以下核心发现具有跨模型的稳健性：

1. **Time_Headway** 系列特征占据绝对主导地位。在 XGBoost 中，Time_Headway_min 的高风险贡献值 (+1.251) 远远领先于第二名 (+0.160)，差距逾一个数量级。该结果在机理上可解释为：最小车头时距直接度量了变道过程中自车与前方车辆的最短反应时间——一旦该时距低于驾驶者感知-反应阈值（通常约为 1.0~2.0 s），碰撞几乎无法避免。温惠英等 [21] 在合流区风险判别中同样发现车头时距均值为重要特征，本研究进一步确认了最小值（而非均值）是具有最强判别力的风险指标变体。
2. 后方距离（**B_Dist**）系列特征位居第二梯队。在 XGBoost 排序中，B_Dist_mean 和 B_Dist_max 分列第 2 和第 4。后方距离表征了自车在变道过程中与后车的空间间

隔：距离越小，一旦变道开始后后车调整不及，发生追尾的潜在严重度就越高。这与 Xue 等 [25] 关于后车风险负荷在变道中占重要比重的发现一致，也符合故障树方法中后车交互是系统失效关键节点 [17, 22] 的基本逻辑。

- 跟车距离最小值（**Following_dist_min**）在两类模型中均稳居前 5。该特征的物理含义最为直接：变道过程中与前车的最近纵向间距直观反映了纵向碰撞的紧迫程度。




图 9: XGBoost SHAP 可解释性分析




图 10: Random Forest SHAP 可解释性分析

4.4.2 跨路段特征稳定性分析

除了全局排序外，各 Cross-Location fold 内部的 SHAP 排序差异揭示了对路段自适应建模的启示：

- 普适性因子（Universal Factors）：Time_Headway 系列特征在所有 5 个 fold 中均位列 Top-3，其重要性排序具有高度的路段间一致性。这表明无论道路类型如何，自行车与前车的时间间隔始终是变道风险最核心的判据，应被纳入所有路段的通用风险评估模型。
- 条件性因子（Conditional Factors）：B_Dist 系列特征在 Loc1~4（路基段与桥梁段，限速 120 km/h）中重要性稳定位于前 5，但在 Loc5（分合流区，限速 100 km/h）中排位下降。这一变化可解释为：在分合流区，主线被汇入车辆挤压，后方车辆的相对位置变化更为频繁和不可预测，使得单一的后方距离均值的判别力减弱；相比之下，速度相关的特征在该场景中的贡献相对上升。
- 模型一致性验证：XGBoost 与 RF 在 Top-5 特征上的高度交叠（交集比例为 4/5）验证了利用两种独立特征归因机制得出的风险因子排序具有稳健性。

5 讨论

5.1 跨路段泛化机理分析

本研究的核心实证发现——树集成模型（XGBoost, RF）在跨路段泛化中显著优于神经网络模型（MLP, LSTM）——可从模型归纳偏置（Inductive Bias）的角度得到解释。树模型的核心运算单元是对特征空间的轴对齐划分（axis-aligned splits），其决策在面对特征分布漂移时具有一定的“分段常数”鲁棒性：只要测试路段样本的特征值落在训练集覆盖的某个叶节点取值范围内，该叶节点的类别投票权重就可以发挥合理的分类作用。相比之下，MLP 的逐层非线性映射会将训练集高维特征间的协方差结构全面编码至权重矩阵中，一旦测试集的协方差结构因路段差异而发生系统性改变——例如分合流区中跟车距离均值与速度方差之间的相关关系与桥梁段显著不同——MLP 就会表现出剧烈的泛化退化。

LSTM 在跨路段泛化中表现不佳（跨路段 $F1 = 0.598$ ，仅略高于 MLP），需要从两个层面理解。第一个层面是样本规模：1,574 条时序序列对于深度循环网络的充分训练而言偏少，限制了 LSTM 从有限样本中提取跨路段通用时序模式的潜力。第二个层面——在本文的实验条件下更关键——是 LSTM 与其他三个模型的输入形态差异带来的结构性劣势：XGBoost、RF 和 MLP 均接受 52 维聚合统计特征（均值 / 标准差 / 最小值 / 最大值），这些特征经过人工设计，具有明确的物理含义（如“最小车头时距”直接等同于“最危险时刻的反应时间储备”），在路段间具备部分不变性——同一物理量在不同路段上虽有分布漂移但其“均值较大者风险较低”的单调关系保持不变；而 LSTM 直接接受原始 75 帧时序数据（ (75×13) 的张量输入），虽然理论上能自主学习时序模式，但在跨

路段场景下，不同路段的变道时序动态模式存在系统性差异——例如 Loc5（分合流区）的变道启动阶段加速积累通常短于 Loc1（路基段），Loc3（桥梁段）驾驶人在纵坡区间倾向于更早开始横向偏移——LSTM 在训练集上习得的时序模式映射到测试集时，其分布漂移的剧烈程度远超经过抽象后的聚合特征的漂移。这一结构性差异使得 LSTM 既面临时序模式的跨路段过拟合，又缺乏聚合特征所提供的人为归纳先验。因此在本文的实验条件下——四条 road 训练、一条 road 测试，且 road 间几何特征差异显著——LSTM 的泛化劣势最为突出。若未来研究能收集每个路段内部大量不同变道事件的时序样本，LSTM 在单一路段内的时序建模优势才有机会转化为跨路段增益。

该发现与 Zheng 等 [29] 在通用交通事故风险预测中关于树模型跨场景稳定性的结论一致，但本研究的边际贡献在于提供了四种模型在同一个多路段 benchmark 上的头对头比较，以及通过留一路段交叉验证获得的定量泛化退化度量。此外，本研究通过随机划分与跨路段划分之间的性能差距对比，将泛化损失分解为“模型类型效应”（树模型 vs 神经网络的固有差距）与“场景效应”（路段几何形态变化导致的额外性能下降），为后续探讨缓解策略提供了分析框架。

5.2 普适性与路段特异性风险因子

SHAP 分析与跨路段 fold 内的排序稳定性分析产生了一个具有实践指导价值的双重分离结论：（1）车头时距系列特征是跨路段普适的粗粒度风险判别指标，（2）距离类特征的重要性取决于具体道路场景。这一分离暗示了一种“通用粗分类 + 场景细调优”的两阶段部署策略：在任一新路段上，可首先使用基于车头时距训练的基础模型进行初步风险筛查，然后根据该路段的几何特征和限速情况决定是否需要——以及如何——调整距离类特征的权重或阈值。这种思路在工程层面适应了变道预警系统需要在多种道路类型上低成本快速部署的现实需求。

5.3 实践应用与部署建议

基于上述发现，本文为变道预警系统的实际部署提出四项具体建议：

1. 模型选型：对于需要在多种道路类型上部署的通用系统，推荐选择 XGBoost 作为基础模型架构。其在跨路段场景中仅 1.4% 的相对性能退化，远优于 MLP 的 4.9%，达到了可以实用部署的水平。
2. 特征子集选择：Time_Headway_min 应作为跨路段通用的核心风险特征强制纳入所有版本的特征集合。对于距离类特征，可考虑根据路段类型（路基段、桥梁段、分合流区）维护不同的特征子集配置或其聚合函数的权重。
3. 分合流区专项处理：鉴于 Loc5 在所有 fold 中的一致性表现最差，建议分合流区部署独立训练的专用模型。理想情况下，应收集多个不同合流区的数据，在合流区子域内部进行域内交叉验证，以避免单一合流区训练的模型在另一个合流区失效。

4. 持续学习机制：随着新路段变道数据的累积，可采用增量学习策略在已有模型基础上微调（fine-tune），而非从零开始完全重新训练。XGBoost 在随机划分基线（F1=0.773）与跨路段（F1=0.759）间的微小差距，表明其学习到的特征重要性模式具有较好的跨路段可迁移性，适合作为增量学习的基础。

5.4 局限性

本研究的局限主要体现在以下方面：（1）全部 5 个路段均位于重庆市范围内，驾驶文化和交通规则具有区域一致性，结论在地域更广、驾驶族群更多样性场景中的延伸性需要进一步验证；（2）风险标签基于 SSM 的指数化评分和固定阈值映射，虽避免了人工打分的主观性偏差，但评分公式中的权重 $\{w_i\}$ 和衰减常数 $\{k_i\}$ 以及等级阈值均为经验取值，尚未以真实碰撞记录为金标准进行端到端校准；（3）1,574 个样本对于深度学习模型——尤其是直接接受原始时序输入的 LSTM——而言偏小，LSTM 的跨路段 F1 仅为 0.598，其较差表现既受样本稀缺约束，也受制于第 5.1 节论述的输入形态差异（时序原始数据 vs 聚合特征），在更深层次上这是“端到端时序学习”与“人工特征工程”两种建模哲学在跨路段泛化场景中的对比结果；（4）基于统计聚合的特征工程丢失了精确的时变信息，而 75 帧内不同时刻的运动学状态可能包含对风险判别有价值的动态模式；（5）未考虑驾驶人异质性（驾驶风格、经验水平）及天气/光照条件对变道风险的系统性影响。

6 结论

本研究基于 CQSkyEyeX 数据集 5 个实际高速公路场景的 1,574 个变道样本，系统评估了 XGBoost、Random Forest、MLP 和 LSTM 四种机器学习模型在变道风险三分类预测中的跨路段泛化性能，并借助 SHAP 可解释性分析揭示了风险因子的跨路段稳定性规律。

主要结论如下：

1. 模型选择对泛化至关重要。树集成模型在跨路段场景中显著优于神经网络模型。XGBoost 取得最优综合表现（跨路段 Weighted F1=0.759±0.069），其从随机划分到跨路段的性能退化仅为 1.4%，具备跨路段部署的现实可行性。MLP 的性能退化高达 4.9%，不建议在跨路段场景中直接使用。
2. 路段几何形态是泛化性能的关键调节变量。路基段和桥梁段之间的模型迁移性良好（F1=0.796~0.821），但从基本路段迁移至分合流区时性能降幅显著（F1=0.631）。分合流区独特的交通交互模式决定了其需要独立训练的专用模型。
3. 车头时距是最稳定 and 最重要的跨路段风险判据。Time_Headway_min 在 XGBoost 和 Random Forest 两个独立 SHAP 分析中均一致占据绝对首位，其高风险的 SHAP 贡献值（+1.251）远超其他所有特征，可作为变道预警系统的通用核心特征。后方距离和跟车距离的重要性则在路段间呈现条件依赖特征。

未来研究可从以下方向深化：（1）将评估扩展至更多样的地理区域和道路类型，构建真正意义上的跨域泛化性能基准；（2）探索域自适应和迁移学习技术能否在不降低基线性能的前提下缩小跨路段泛化差距；（3）将本研究的时间窗固定策略替换为自适应窗口长度选择机制；（4）研究少样本学习策略在仅有少量新路段样本可用时的模型快速适配问题。

致谢：本研究使用的 CQSkyEyeX 数据集由重庆交通大学交通运输学院徐进教授团队公开提供 [23]，特此致谢。

参考文献

- [1] K. Ahmed et al. Generalizable lane change prediction: A multi-dataset domain adaptation approach. *Transportation Research Part C*, 155:104299, 2023.
- [2] Authors. Ds-lstm for lane change risk considering driving style. *Proc. SPIE ITSSC*, 2024. [VERIFY].
- [3] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [4] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proc. 22nd ACM SIGKDD*, pages 785–794, 2016. doi: 10.1145/2939672.2939785.
- [5] Yidong Feng, Guang Chen, Kai Kang, Yunfei Zhao, and Tong Zhu. A real-time risk assessment model for highway merging behavior based on trajectory data. *Highway*, (11): 303–311, 2025.
- [6] J.C. Hayward. Near-miss determination through use of a scale of danger. *Highway Research Record*, 384:24–34, 1971.
- [7] Sepp Hochreiter and Jurgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [8] Y. Huang et al. Transferability assessment of driving risk prediction models across different highway segments. *Transportation Research Record*, 2677(3):212–225, 2025.
- [9] C. Hyden. The development of a method for traffic safety evaluation: The swedish traffic conflicts technique. *Lund Institute of Technology Bulletin*, 70, 1987.
- [10] Robert Krajewski, Julian Bock, Laurent Kloecker, and Lutz Eckstein. The highd dataset: A drone dataset of naturalistic vehicle trajectories on german highways for validation of highly automated driving systems. In *Proc. 21st IEEE International Conference on Intelligent Transportation Systems (ITSC)*, pages 2118–2125, 2018. doi: 10.1109/ITSC.2018.8569552.

- [11] Y. Li et al. Shap-based interpretable lane change risk prediction model. *Journal of Advanced Transportation*, 2024:8837542, 2024.
- [12] Zhenyu Liu and Qiaojun Xiang. F-f diagram: A two-dimensional surrogate safety indicator based on field theory for lane change risk assessment. *IEEE Transactions on Intelligent Transportation Systems*, 26(7):10694–10707, 2025. doi: 10.1109/TITS.2025.3550643.
- [13] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4768–4777, 2017.
- [14] Scott M. Lundberg et al. From local explanations to global understanding with explainable ai for trees. *Nature Machine Intelligence*, 2:56–67, 2020. doi: 10.1038/s42256-019-0138-9.
- [15] Michiel M. Minderhoud and Piet H.L. Bovy. Extended time-to-collision measures for road traffic safety assessment. *Accident Analysis and Prevention*, 33(1):89–97, 2001. doi: 10.1016/S0001-4575(00)00019-1.
- [16] K. Ozbay, H. Yang, B. Bartin, and S. Mudigonda. Derivation and validation of a new time-to-collision metric for automated safety analysis. *Transportation Research Record*, 2078:72–81, 2008.
- [17] Hyunjin Park, Cheol Oh, Jaepil Moon, and Seongho Kim. Development of a lane change risk index using vehicle trajectory data. *Accident Analysis and Prevention*, 110:1–8, 2018. doi: 10.1016/j.aap.2017.10.015.
- [18] Chen Wang, Yuanchang Xie, Helai Huang, and Pan Liu. A review of surrogate safety measures and their applications in connected and automated vehicles safety modeling. *Accident Analysis and Prevention*, 157:106157, 2021. doi: 10.1016/j.aap.2021.106157.
- [19] Tao Wang, Chengmin Li, Wenqiang Chen, Junhua Wang, and Ying'en Ge. Highway traffic conflict risk field construction method considering behavioral stochasticity. *China Journal of Highway and Transport*, 39(2):258–278, 2026.
- [20] Z. Wang et al. Location-specific and generalizable driving risk factors: A multi-site naturalistic driving study. *Accident Analysis and Prevention*, 212:107935, 2025.
- [21] Huiying Wen, Kunhuo Huang, Zhe Chen, Sheng Zhao, Yuqing Hu, and Junda Huang. Research on merging characteristics and safety of expressway based on exid. *Journal of South China University of Technology (Natural Science Edition)*, 53(8):50–60, 2025.
- [22] Jiabin Wu, Huiying Wen, and Weiwei Qi. A new method of temporal and spatial risk estimation for lane change considering conventional recognition defects. *Accident Analysis and Prevention*, 148:105796, 2020. doi: 10.1016/j.aap.2020.105796.

- [23] Jin Xu, Cunshu Pan, Zhenhua Dai, and Heshan Zhang. Cqskyeyex: A drone dataset of vehicle trajectory on chinese expressways. In *Smart Transportation and Green Mobility Safety*, volume 1201 of *Lecture Notes in Electrical Engineering*, pages 463–479. Springer, 2024. doi: 10.1007/978-981-97-3052-0_34.
- [24] Jin Xu, Cunshu Pan, Zhenhua Dai, and Heshan Zhang. An approach for accurately extracting vehicle trajectory from aerial videos based on computer vision. *Measurement*, 242:116212, 2024. doi: 10.1016/j.measurement.2024.116212.
- [25] Qingwen Xue, Ke Wang, Jian John Lu, Yingying Xing, Xin Gu, and Meng Zhang. An improved risk estimation model of lane change using naturalistic vehicle trajectories. *Journal of Transportation Safety and Security*, 2022. doi: 10.1080/19439962.2022.2147612.
- [26] Y. Zhang et al. Cross-scene transferability of car-following and lane-changing models. *Transportation Research Part B*, 170:1–18, 2023.
- [27] Y. Zhang et al. Cross-dataset transferability of lane change risk models. *Analytic Methods in Accident Research*, 46:100376, 2025.
- [28] X. Zheng and Y. Liu. Multi-vehicle type lane-changing risk recognition framework. *Electronics*, 13(8):1523, 2024.
- [29] Y. Zheng et al. A comparative analysis of machine learning models for real-time crash risk prediction. *Journal of Safety Research*, 90:155–167, 2024.